

ATLAS 约束生产方法、V20 AUTOSAR 实验与审稿意见回应

Human-governed, test-backed, AI-assisted constraint engineering

项目	内容
稿件	SOSYM-26-00005681 — ATLAS
用途	论文方法与评估改写、逐点审稿回复、材料复核
正式证据版本	V20；统一 60 项生成 + 100 个受控修复设计单元
日期	2026-09-02

核心结论 本轮不是把旧批次中的四个失败工件在结束后手工改好。通用修复已进入 Phase 1→IR→Phase 2→确定性渲染的正常方法路径，随后从新冻结版本统一执行全部正式样本。旧批次只保留为开发诊断，不进入论文分母。

1. 本文档如何使用

本文档与两个 TeX 文件配套：一份替换评估章节，一份替换摘要、方法、结论和数据可得性等其余段落。正文应优先采用 TeX；本文档用于方法审计、逐点回复和数据边界核对。

- 论文主数据只使用 V20：60 个生成观察与 100 个受控修复设计单元。
- V17/V18/V19 开发批次与诊断回放不得与 V20 拼接、汇总或作为论文正式结果。
- vLLM 机制实验与 AUTOSAR provider 实验分开：前者观察 token-level grammar masking，后者使用 strict JSON Schema + 确定性 ARXML 物化。

2. 面向 MDE 社区的稳定概念

为避免把领域实例写成通用方法，正文使用“结构化工程工件”“模型实例/序列化工件”“约束编译”和“模型转换”作为上位概念；AUTOSAR、ARXML、XSD 路径和端口/接口规则只作为本研究的领域绑定。

MDE 概念	ATLAS 通用职责	AUTOSAR 实例化
--------	------------	-------------

MDE 概念	ATLAS 通用职责	AUTOSAR 实例化
输入模型形成	将自然语言义务编译为带身份与基数的语义 IR	英文组件需求 → 组件/接口/端口/事件的身份槽
模型转换	IR 到目标元模型实例的确定性物化	IR → 按 AUTOSAR 4.2.2 XSD 顺序生成 ARXML
一致性检查	独立验证目标实例是否满足结构与需求义务	XSD、artifact profile、selection obligations、本地跨文件引用
模型修复	根据定位 finding 选择枚举 typed edit site，再确定性重物化	修复值、引用、缺失结构和 XSD 顺序等预注册故障
证据与追踪	冻结输入、实现、执行与接受判定的内容身份	schedule、Neo4j context、XSD、provider ledger、ARXML 与独立复核哈希

术语边界 不要把所有结构化工程工件统称为“AUTOSAR 模型”。通用论述写 model instance / structured engineering artifact；只有描述本案例时才写 AUTOSAR component ARXML bundle。

3. 约束生产：从规范证据到可执行规则

ATLAS 的约束库不是由 LLM 端到端自动生成。它是一个有人负责语义决定、以测试和哈希为发布门的证据工程过程。

1. 确定权威规范范围、版本、章节和语言；本实例的规范与测试输入均明确标注为英文。
2. 确定性提取约束 ID、章节路径、原文、行范围、解析状态与 SHA-256；原始证据不可由后续摘要覆盖。
3. AI 仅提出摘要、分类、绑定候选、规则骨架和测试建议；所有结果保持 provisional。
4. 作者/领域评审者决定规范性、重要性、适用范围、冲突处理、core/must 与发布状态。
5. 将约束绑定到元模型类、属性、XML 标签、wrapper、路径和引用目标；XSD 验证顺序与基数。
6. 只有在给定工件范围内可观察且失败证据可定位的约束，才资格化为自动验证器；缺证据时 fail-closed。
7. 编译为 typed DSL 或 Python validator；XSD 是结构基线，SHACL/SMT 只用于适合的闭世界子集。
8. 单元、负例、回归、注册、源码哈希与运行时门禁全部通过后才发布，并固定到实验冻结清单。

人工语义评审与人工验证义务不同：前者决定规范如何解释以及规则是否发布；后者表示判断依赖 RTE、源代码、部署配置、运行轨迹或项目意图，不能由当前 ARXML 静态验证器伪造 PASS/FAIL。

4. 框架内修复：三个不可混淆的层次

层次	发生位置	做什么	论文写法
IR 编译/归一化/恢复	模型结构化响应之后、XML 物化之前	绑定需求锚点、抑制冗余选择、修正近路径、计算 wrapper 身份/基数	framework-internal deterministic IR normalization/recovery
Validator-localised typed repair	完整工件被独立验证为 FAIL 后	依据 finding 枚举 edit site，模型选索引/值，确定性渲染，独立验证器接受	validator-localized typed repair loop
Transport continuation	一次逻辑 provider 请求内部	只处理无结构化响应的瞬态网络失败，保留同一 logical_request_id	bounded operational transport continuation；不是修复结果

方法边界 正式写法是：诊断暴露了通用 IR 编译缺口；该缺口被实现为正常方法路径中的确定性预物化归一化；代码修复后冻结 V20；全部 60+100 单元按统一版本重新执行。不得写“人工补回”或“重跑到成功”。

5. V20 实验设计与复现条件

项目	冻结值
生成设计	20 个内部编写英文案例 × 3 固定 seed = 60；case 为稳定性分析单位
修复设计	85 个 core fixed-operator 单元 + 15 个预声明 substitution 单元；case×mutation 为统计单位
模型	gpt-5.6-luna；reasoning effort=low；temperature=provider default 1.0
结构化输出	provider strict JSON Schema；fallback 禁用；ARXML 由固定 XSD 驱动的确定性 renderer 生成
schema	AUTOSAR Classic 4.2.2 XSD；文件哈希固定
约束上下文	Neo4j read-only；1085 constraint cards；context SHA-256 2ad8bfd31daae20c624bea39d955543ae0ab2544b61c6f06e481291011ba055b
运行环境	Windows-11-10.0.26200-SP0；CPython 3.12.13；Neo4j Kernel 2026.03.1

项目	冻结值
凭据	不写入冻结清单、日志、哈希或交付包；复现者自行配置 .env

正式运行之前通过了客户端/账本 23 项、实验编排 75 项、目标结构/编译/验证 266 项、冻结 42 项测试，并完成零网络 60/60 全链路门禁。

6. V20 正式结果

6.1 生成与独立验证

指标	结果	解释
终态	60/60	所有预定观察均有终态
XSD-valid	60/60	每个工件束内全部 ARXML 文件 XSD PASS
Independent strict PASS	60/60	XSD + profile + task obligations + local references
案例三次稳定 PASS	20/20	稳定性单位是 case，不把 60 次视为相互独立
平均时长	64.71 s/run	仅为执行量，不推导人效
平均 token	199,457.93/run	无冻结价格表，不报告金额

XSD 与需求满足仍然是不同性质的门：本轮若两者均为 60/60，只说明观测结果一致，不能推出 XSD 包含语义验证。受控变异中的 wrong value、missing path/reference 等单元说明 XSD-valid 工件仍可违反需求义务。

6.2 正常路径中的框架干预

IR 操作	次数
absent_value_repair_count	0
derived_anchor_identity_count	175
multi_anchor_expansion_count	10
resolved_unsupported_count	0
structured_anchor_chain_repair_count	50
structured_anchor_index_repair_count	13

IR 操作	次数
structured_value_anchor_binding_count	161
suppressed_phase1_selection_count	118
TOTAL	527

共应用 1734 个需求义务；49 个运行实际触发 527 次 IR 归一化/恢复。这是正式运行中的可审计执行证据。

provider 审计记录 180 个逻辑请求、184 次实际发送、2 个触发传输续传的逻辑请求。网络续传不增加样本分母。

6.3 受控 typed repair

分析层	operator	strict restoration	rate
core	empty_init_value	17/17	100.00%
core	missing_event_behavior_path	14/14	100.00%
core	missing_required_comspec	17/17	100.00%
core	wrong_init_value	17/17	100.00%
core	wrong_xsd_order	20/20	100.00%
substitution	empty_provided_interface_ref	3/3	100.00%
substitution	missing_component_short_name	3/3	100.00%
substitution	missing_provided_port	3/3	100.00%
substitution	missing_required_interface_ref	3/3	100.00%
substitution	wrong_provided_interface_ref	3/3	100.00%

core 层 85/85；substitution 层 15/15。两个层次必须分开报告。独立验证器还要求 exact-original recovery，避免修复候选引入不可见的旁路修改。

正式生成观察到 0 个自然失败。若该值为 0，论文必须写 natural-failure repair effectiveness is not estimable，不能写 100%。

7. 对编辑和审稿人的逐点回应

审稿关注	修订与证据
术语不一致、难读	删除 CVG 等漂移术语；全篇固定为 requirement compilation → semantic IR → deterministic materialization → independent validation → typed repair，并增加贯穿示例和 MDE 映射。
通用方法与 AUTOSAR 实现边界模糊	将贡献改为在 AUTOSAR 实例化并评估的方法论。通用部分是责任划分、阶段接口和证据契约；元模型绑定、XSD 路径和规则是领域实现。跨域效果明确留作未来工作。
数据来源、语言和偏差不可核查	明确 20 个需求案例是内部编写的英文数据，不是官方/公开 benchmark；发布 YAML、渲染 prompt、dataset card、tier 与 SHA-256；在 Threats 中承认作者构造偏差。
不同模型使 RQ 不可比	V20 生成和修复使用一个固定 gpt-5.6-luna 配置，不执行跨模型排名。vLLM/Qwen 只作为分开的机制观察，不与 AUTOSAR 成功率比较。
constrained decoding 概念不准确	明确区分 token-level logit masking 与 provider strict JSON Schema。AUTOSAR V20 不声称看到 token mask；本地 vLLM 另行提供 grammar intervention 证据。
AGR 缺少定量证据	新增 100 个预注册受控设计单元：core 85/85、substitution 15/15，并报告检测、严格恢复、exact bytes、provider ledger 与 token。
人机协同投入未量化	本轮没有开展人因研究，因此删除减少人工时间/成本/生产率的主张。文档区分 human semantic review、manual validation obligation 与自动 repair。
实现细节不足	发布冻结 source snapshot、strict schema、IR 编译器、renderer、validator、typed repair、schedule、Neo4j context、provider transition ledger 和独立验证脚本。
系统级语义仍具挑战	PASS 限定为组件工件束的 XSD/profile/task obligations/local references，不推广为完整 ECU、RTE、网络、部署、BSW 或全 AUTOSAR 合规。
日志的工程效用未验证	撤回把 raw token mask aggregate 当作工程诊断价值的表述。修复使用高层 validator finding、模型路径和枚举 edit site；未执行 IDE 或人因对比。

8. 可直接用于回复信的英文表述

Method and scope

We have rewritten ATLAS as a human-governed, test-backed, AI-assisted constraint-engineering method instantiated and evaluated in AUTOSAR. The domain-independent contribution is the allocation of responsibilities and evidence interfaces; the AUTOSAR metamodel bindings, XSD paths, and validation predicates remain domain-specific. We no longer claim empirically demonstrated cross-domain effectiveness.

Dataset and comparability

The revised evaluation uses 20 internally authored English requirement cases, three fixed repetitions per case, and one fixed provider-model configuration for both generation and controlled repair. We publish the source YAML, deterministic rendered prompts, provenance metadata, schedules, and hashes. The separate local vLLM study is reported only as a mechanism study and is not compared with or pooled into the AUTOSAR outcome rates.

Repair evidence

We integrated the diagnosed structural corrections into the normal IR compiler before freezing V20 and then executed the complete cohort under that single version. The formal run records framework-internal normalisation events before XML materialisation. In a separate preregistered controlled repair protocol, the validator localises a failure, the model selects among enumerated typed edit sites, a deterministic renderer applies the candidate, and an independent evaluator decides acceptance. The core and substitution layers are reported separately (85/85 and 15/15); no human-effort claim is made.

Constrained decoding boundary

We now distinguish token-level grammar-constrained decoding from provider schema-bounded structured output. The AUTOSAR study uses strict JSON Schema for semantic intermediate representations followed by deterministic XSD-driven ARXML materialisation; it does not expose token-level masks. The vLLM experiment provides the separate token-intervention evidence.

9. 论文修改文件与使用顺序

文件	用途	状态
ATLAS_new_evaluation_section.tex	替换完整 Evaluation; 所有数字来自 V20 独立复核	直接使用
ATLAS_remaining_sections.tex	摘要、引言、方法、repair、结论、Data Availability 替换块	与评估文件同步使用
AUTOSAR_REQUIREMENT_PROVENANCE_AND_DESIGN.md	约束来源、语言、人工/AI 责任、case provenance	方法与材料说明

文件	用途	状态
AUTOSAR_V20_FORMAL_EXPERIMENT_RESULTS_AND_PAPER_BOUNDARY_2026-09-02.md	结果解释、可写/不可写、复现环境、哈希	作者核对与论文数据边界
本 DOCX	逐点审稿回复和方法说明	作为 response-to-reviewers 的基础

10. 冻结身份与独立复核

Evidence	SHA-256
Freeze content	213fdaf4de45b44cb284af15dfc9723ab30caa67eb472212938ef2f0bf0da2c2
Formal schedule	8ae535ba5ddc7e40ee98f9d699f097b4b6bf9b2f81c59e1bc911b853a331574c
Generation results	5da533af826edcabca4c08632ffdc684ef31de31a868046be96f70f851ec9ef6
Repair results	15b0cd2f2f65756ca6373e9abb7fcfd68ca108e67bccb77bf329e89d111412c
Generation independent verification	7c9afa664eb36f99bab2794935f8772210c8192efe79f5ce44583220b55be4ba
Repair independent verification	01037b25e7b3af1ff65d0546a3e84bc1acc6d6e5e5842b498f058a6fa60cc3af
Framework intervention audit	fadddd30ea6e39124a951ac301837895601c21912aad5579307e1ca32a71204cb
Neo4j context	2ad8bfd31daae20c624bea39d955543ae0ab2544b61c6f06e481291011ba055b
AUTOSAR 4.2.2 XSD	3c89b2f16d1981eb04e12c7fbe035e7cd6fbd79965a47ff6cf6d6b878feb71ad

复核状态 独立复核重新计算源文件哈希并重新运行 XSD、artifact profile、selection obligations 和 local-reference evaluator；不会修改模型输出或原始 ARXML。

11. 最终边界清单

- 不声称完整 AUTOSAR 或系统级合规。
- 不声称跨域效果已得到验证。
- 不声称 provider JSON Schema 提供可观测 token-level masking。
- 不把规则库规模当成每个工件的 evaluated-rule 数。
- 不合并 core 与 substitution 修复率。
- 不把自然失败为零写成自然故障修复率 100%。
- 不声称降低人工时间、成本或提高生产率。
- 不把旧批次、诊断四例或网络发送次数并入正式样本。